Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных.

In [2]:

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Загрузка и первичный анализ данных

In [3]:

```
# Будем использовать только обучающую выборку
data = pd.read_csv('winemag-data-130k-v2.csv', sep=",")
```

In [4]:

```
# размер набора данных
data.shape
```

Out[4]:

```
(129971, 14)
```

In [5]:

```
# типы колонок
data.dtypes
```

Out[5]:

```
Unnamed: 0                 int64
country                   object
description               object
designation               object
points                     int64
price                   float64
province                  object
region_1                  object
region_2                  object
taster_name               object
taster_twitter_handle     object
title                     object
variety                   object
winery                    object
dtype: object
```

In [6]:

```
# проверим есть ли пропущенные значения
data.isnull().sum()
```

Out[6]:

```
Unnamed: 0                  0
country                    63
description                 0
designation             37465
points                      0
price                    8996
province                   63
region_1                21247
```

```
region_2                 79460
taster_name              26244
taster_twitter_handle    31213
title                        0
variety                      1
winery                       0
dtype: int64
```

In [7]:

```
# Первые 5 строк датасета
data.head()
```

Out[7]:

	Unnamed: 0	country	description	designation	points	price	province	region_1	region_2	taster_name	taster_twitter_h
0	0	Italy	Aromas include tropical fruit, broom, brimston...	Vulkà Bianco	87	NaN	Sicily & Sardinia	Etna	NaN	Kerin O'Keefe	@kerino
1	1	Portugal	This is ripe and fruity, a wine that is smooth...	Avidagos	87	15.0	Douro	NaN	NaN	Roger Voss	@voss
2	2	US	Tart and snappy, the flavors of lime flesh and...	NaN	87	14.0	Oregon	Willamette Valley	Willamette Valley	Paul Gregutt	@paul
3	3	US	Pineapple rind, lemon pith and orange blossom ...	Reserve Late Harvest	87	13.0	Michigan	Lake Michigan Shore	NaN	Alexander Peartree	
4	4	US	Much like the regular bottling from 2012, this...	Vintner's Reserve Wild Child Block	87	65.0	Oregon	Willamette Valley	Willamette Valley	Paul Gregutt	@paul

In [8]:

```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```

```
Всего строк: 129971
```

Обработка пропусков в данных

Простые стратегии - удаление или заполнение нулями

In [9]:

```
# Удаление колонок, содержащих пустые значения
data_new_1 = data.dropna(axis=1, how='any')
(data.shape, data_new_1.shape)
```

Out[9]:

Out[9]:

```
((129971, 14), (129971, 5))
```

Удаление колонок, содержащих пустые значения приведет к сокращению колонок с **14** до **5**

In [10]:

```
# Удаление строк, содержащих пустые значения
data_new_2 = data.dropna(axis=0, how='any')
(data.shape, data_new_2.shape)
```

Out[10]:

```
((129971, 14), (22387, 14))
```

Удаление строк, содержащих пустые значения приведет к сокращению строк с **129971** до **22387**

In [11]:

```
data.head()
```

Out[11]:

	Unnamed: 0	country	description	designation	points	price	province	region_1	region_2	taster_name	taster_twitter_h
0	0	Italy	Aromas include tropical fruit, broom, brimston...	Vulkà Bianco	87	NaN	Sicily & Sardinia	Etna	NaN	Kerin O'Keefe	@kerino
1	1	Portugal	This is ripe and fruity, a wine that is smooth...	Avidagos	87	15.0	Douro	NaN	NaN	Roger Voss	@voss
2	2	US	Tart and snappy, the flavors of lime flesh and...	NaN	87	14.0	Oregon	Willamette Valley	Willamette Valley	Paul Gregutt	@paul
3	3	US	Pineapple rind, lemon pith and orange blossom ...	Reserve Late Harvest	87	13.0	Michigan	Lake Michigan Shore	NaN	Alexander Peartree	
4	4	US	Much like the regular bottling from 2012, this...	Vintner's Reserve Wild Child Block	87	65.0	Oregon	Willamette Valley	Willamette Valley	Paul Gregutt	@paul

In [12]:

```
# Заполнение всех пропущенных значений нулями
# В данном случае это некорректно, так как нулями заполняются в том числе категориальные колонки
data_new_3 = data.fillna(0)
data_new_3.head()
```

Out[12]:

	Unnamed:

	Unnamed: 0	country	description	designation	points	price	province	region_1	region_2	taster_name	taster_twitter_h
0	0	Italy	Aromas include tropical fruit, broom, brimston...	Vulkà Bianco	87	0.0	Sicily & Sardinia	Etna	0	Kerin O'Keefe	@kerino
1	1	Portugal	This is ripe and fruity, a wine that is smooth...	Avidagos	87	15.0	Douro	0	0	Roger Voss	@voss
2	2	US	Tart and snappy, the flavors of lime flesh and...	0	87	14.0	Oregon	Willamette Valley	Willamette Valley	Paul Gregutt	@paul
3	3	US	Pineapple rind, lemon pith and orange blossom ...	Reserve Late Harvest	87	13.0	Michigan	Lake Michigan Shore	0	Alexander Peartree	
4	4	US	Much like the regular bottling from 2012, this...	Vintner's Reserve Wild Child Block	87	65.0	Oregon	Willamette Valley	Willamette Valley	Paul Gregutt	@paul

"Внедрение значений" - импьютация **(imputation)**

Обработка пропусков в числовых данных

In [13]:

```
# Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(co
l, dt, temp_null_count, temp_perc))
```

```
Колонка price. Тип данных float64. Количество пустых значений 8996, 6.92%.
```

In [14]:

```
# Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
```

Out[14]:

	price
0	NaN
1	15.0

	price
2	11.0
3	13.0
4	65.0
...	...
129966	28.0
129967	75.0
129968	30.0
129969	32.0
129970	21.0

129971 rows × 1 columns

In [15]:

```
# Гистограмма по признакам
for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```

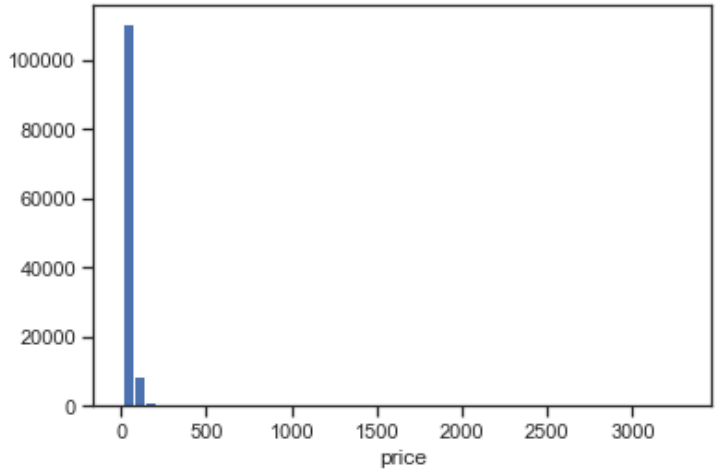

In [16]:

```
data_num_price = data_num[['price']]
data_num_price.head()
```

Out[16]:

	price
0	NaN
1	15.0
2	14.0
3	13.0
4	65.0

In [17]:

```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
```

In [18]:

```
# Фильтр для проверки заполнения пустых значений
indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(data_num_price)
mask_missing_values_only
```

Out[18]:

```
array([[ True],
       [False],
       [False],
       ...,
       [False],
       [False],
       [False]])
```

Попробуем заполнить пропущенные значения в колонке **price** значениями, вычисленными по среднему арифметическому, медиане и моде.

In [20]:

```
strategies=['mean', 'median', 'most_frequent']
```

In [23]:

```
def test_num_impute(strategy_param):
    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(data_num_price)
    return data_num_imp[mask_missing_values_only]
```

In [24]:

```
strategies[0], test_num_impute(strategies[0])
```

Out[24]:

```
('mean',
 array([35.36338913, 35.36338913, 35.36338913, ..., 35.36338913,
        35.36338913, 35.36338913]))
```

In [25]:

```
strategies[1], test_num_impute(strategies[1])
```

Out[25]:

```
('median', array([25., 25., 25., ..., 25., 25., 25.]))
```

In [26]:

```
strategies[2], test_num_impute(strategies[2])
```

Out[26]:

```
('most_frequent', array([20., 20., 20., ..., 20., 20., 20.]))
```

In [27]:

```
# Более сложная функция, которая позволяет задавать колонку и вид импьютации
def test_num_impute_col(dataset, column, strategy_param):
    temp_data = dataset[[column]]

    indicator = MissingIndicator()
    mask_missing_values_only = indicator.fit_transform(temp_data)

    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(temp_data)

    filled_data = data_num_imp[mask_missing_values_only]

    return column, strategy_param, filled_data.size, filled_data[0], filled_data[filled_
data.size-1]
```

In [29]:

```
data[['price']].describe()
```

Out[29]:

	price
count	120975.000000
mean	35.363389
std	41.022218
min	4.000000
25%	17.000000
50%	25.000000
75%	42.000000
max	3300.000000

In [30]:

```
test_num_impute_col(data, 'price', strategies[0])
```

Out[30]:

```
('price', 'mean', 8996, 35.363389129985535, 35.363389129985535)
```

In [31]:

```
test_num_impute_col(data, 'price', strategies[1])
```

Out[31]:

```
('price', 'median', 8996, 25.0, 25.0)
```

In [32]:

```
test_num_impute_col(data, 'price', strategies[2])
```

Out[32]:

```
('price', 'most_frequent', 8996, 20.0, 20.0)
```

Получили вычисления по среднему арифметическому, медиане и моде, которые немного отличаются

Обработка пропусков в категориальных данных

In [34]:

```
# Выберем категориальные колонки с пропущенными значениями
# Цикл по колонкам датасета
cat_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='object'):
        cat_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(co
l, dt, temp_null_count, temp_perc))
```

```
Колонка country. Тип данных object. Количество пустых значений 63, 0.05%.
Колонка designation. Тип данных object. Количество пустых значений 37465, 28.83%.
Колонка province. Тип данных object. Количество пустых значений 63, 0.05%.
Колонка region_1. Тип данных object. Количество пустых значений 21247, 16.35%.
Колонка region_2. Тип данных object. Количество пустых значений 79460, 61.14%.
Колонка taster_name. Тип данных object. Количество пустых значений 26244, 20.19%.
Колонка taster_twitter_handle. Тип данных object. Количество пустых значений 31213, 24.02
%.
Колонка variety. Тип данных object. Количество пустых значений 1, 0.0%.
```

- Колонки, содержащие менее **30%** пропусков выбираем для построения модели

- Колонки, содержащие менее **30%** пропусков выбираем для построения модели.
- Колонки, содержащие более **30%** пропусков не выбираем для построения модели.

In [35]:

```
cat_temp_data = data[['region_1']]
cat_temp_data.head()
```

Out[35]:

	region_1
0	**Etna**
1	**NaN**
2	**Willamette Valley**
3	**Lake Michigan Shore**
4	**Willamette Valley**

In [36]:

```
cat_temp_data['region_1'].unique()
```

Out[36]:

```
array(['Etna', nan, 'Willamette Valley', ..., 'Del Veneto',
       'Bardolino Superiore', 'Paestum'], dtype=object)
```

In [37]:

```
cat_temp_data[cat_temp_data['region_1'].isnull()].shape
```

Out[37]:

```
(21247, 1)
```

In [38]:

```
# Импьютация наиболее частыми значениями
imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
```

Out[38]:

```
array([['Etna'],
       ['Napa Valley'],
       ['Willamette Valley'],
       ...,
       ['Alsace'],
       ['Alsace'],
       ['Alsace']], dtype=object)
```

In [39]:

```
# Пустые значения отсутствуют
np.unique(data_imp2)
```

Out[39]:

```
array(['Abruzzo', 'Adelaida District', 'Adelaide', ...,
       'Yorkville Highlands', 'Yountville', 'Zonda Valley'], dtype=object)
```

In [40]:

```
# Импьютация константой
imp3 = SimpleImputer(missing_values=np.nan, strategy='constant', fill_value='NA')
data_imp3 = imp3.fit_transform(cat_temp_data)
data_imp3
```

Out[40]:

```
array([['Etna'],
       ['NA'],
       ['Willamette Valley'],
       ...,
       ['Alsace'],
       ['Alsace'],
       ['Alsace']], dtype=object)
```

In [41]:

```
np.unique(data_imp3)
```

Out[41]:

```
array(['Abruzzo', 'Adelaida District', 'Adelaide', ...,
       'Yorkville Highlands', 'Yountville', 'Zonda Valley'], dtype=object)
```

In [42]:

```
data_imp3[data_imp3=='NA'].size
```

Out[42]:

```
21247
```

Таким образом, в колонку **region_1** вставлено **21247 "NA",** вместо пропущенных значений.

Преобразование категориальных признаков в числовые

In [43]:

```
cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
cat_enc
```

Out[43]:

	c1
0	**Etna**
1	**Napa Valley**
2	**Willamette Valley**
3	**Lake Michigan Shore**
4	**Willamette Valley**
...	**...**
129966	**Napa Valley**
129967	**Oregon**
129968	**Alsace**
129969	**Alsace**
129970	**Alsace**

129971 rows × 1 columns

Кодирование категорий целочисленными значениями - label encoding

In [44]:

```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

In [45]:

```
le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])
```

In [46]:

```
cat_enc['c1'].unique()
```

Out[46]:

```
array(['Etna', 'Napa Valley', 'Willamette Valley', ..., 'Del Veneto',
       'Bardolino Superiore', 'Paestum'], dtype=object)
```

In [47]:

```
np.unique(cat_enc_le)
```

Out[47]:

```
array([   0,    1,    2, ..., 1226, 1227, 1228])
```

Кодирование категорий наборами бинарных значений - one-hot encoding

In [48]:

```
ohe = OneHotEncoder()
cat_enc_ohe = ohe.fit_transform(cat_enc[['c1']])
```

In [49]:

```
cat_enc.shape
```

Out[49]:

```
(129971, 1)
```

In [50]:

```
cat_enc_ohe.shape
```

Out[50]:

```
(129971, 1229)
```

In [51]:

```
cat_enc_ohe
```

Out[51]:

```
<129971x1229 sparse matrix of type '<class 'numpy.float64'>'
 with 129971 stored elements in Compressed Sparse Row format>
```

In [52]:

```
cat_enc_ohe.todense()[0:10]
```

Out[52]:

```
matrix([[0., 0., 0., ..., 0., 0., 0.],
        [0., 0., 0., ..., 0., 0., 0.],
        [0., 0., 0., ..., 0., 0., 0.],
        ...,
        [0., 0., 0., ..., 0., 0., 0.],
        [0., 0., 0., ..., 0., 0., 0.],
        [0., 0., 0., ..., 0., 0., 0.]])
```

In [53]:

```
cat_enc.head(10)
```

Out[53]:

	c1
0	Etna
1	Napa Valley
2	Willamette Valley
3	Lake Michigan Shore
4	Willamette Valley
5	Navarra
6	Vittoria
7	Alsace
8	Napa Valley
9	Alsace

Pandas get_dummies - быстрый вариант **one-hot** кодирования

In [54]:

```
pd.get_dummies(cat_enc).head()
```

Out[54]:

	c1_Abruzzo	c1_Adelaida District	c1_Adelaide	c1_Adelaide Hills	c1_Adelaide Plains	c1_Aglianico d'Irpinia	c1_Aglianico del Beneventano	c1_Aglianico del Taburno	c1_Aglianico del Vulture	c1
0	0	0	0	0	0	0	0	0	0	
1	0	0	0	0	0	0	0	0	0	
2	0	0	0	0	0	0	0	0	0	
3	0	0	0	0	0	0	0	0	0	
4	0	0	0	0	0	0	0	0	0	

5 rows × 1229 columns

In [55]:

```
pd.get_dummies(cat_temp_data, dummy_na=True).head()
```

Out[55]:

	region_1_Abruzzo	region_1_Adelaida District	region_1_Adelaide	region_1_Adelaide Hills	region_1_Adelaide Plains	region_1_Aglianico d'Irpinia	region_1_del Be
0	0	0	0	0	0	0	
1	0	0	0	0	0	0	
2	0	0	0	0	0	0	
3	0	0	0	0	0	0	
4	0	0	0	0	0	0	

5 rows × 1230 columns

Масштабирование данных

- **MinMax** масштабирование:

$$x_{\text{новый}}$$
$$x_{\text{старый}}$$
$$= \frac{- min(X)}{max(X)}$$
$$- min(X)$$

В этом случае значения лежат в диапазоне от **0** до **1.**

- Масштабирование данных на основе **Z-оценки**:

$$x_{\text{новый}}$$
$$x_{\text{старый}}$$
$$= \frac{- AVG(X)}{\sigma(X)}$$

В этом случае большинство значений попадает в диапазон от **-3** до **3.**

где X **-** матрица объект-признак, $AVG(X)$ **-** среднее значение, σ **-** среднеквадратичное отклонение**.**

In [56]:

```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

MinMax масштабирование

In [57]:

```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['price']])
```

In [58]:

```
plt.hist(data['price'], 50)
plt.show()
```

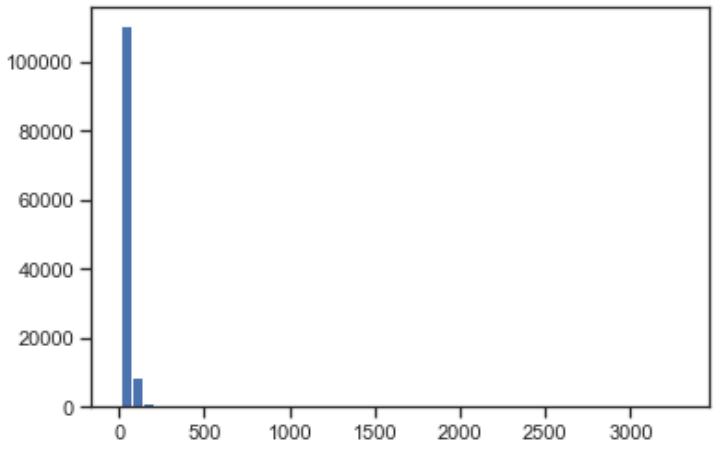

In [59]:

```
plt.hist(sc1_data, 50)
plt.show()
```

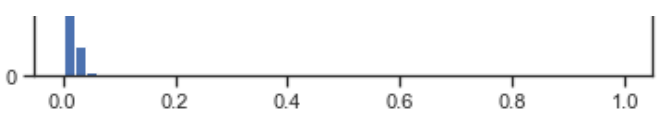

Таким образом, получили значения из начальных **0-3000** в конечные **0-1.**

Масштабирование данных на основе Z-оценки - StandardScaler

In [60]:

```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['price']])
```

In [62]:

```
plt.hist(sc2_data, 50)
plt.show()
```

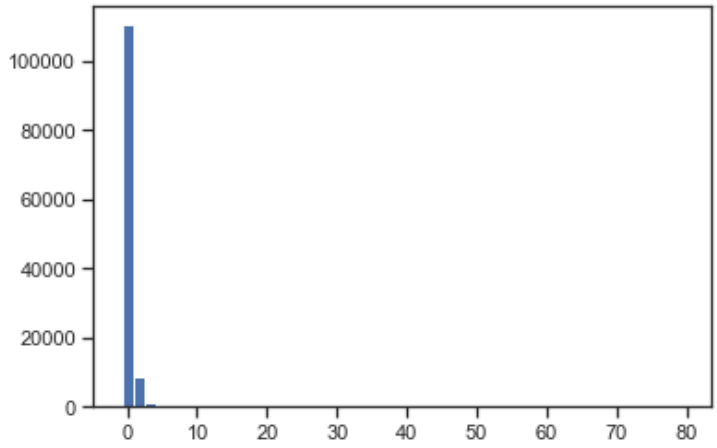

Таким образом, получили значения из начальных **0-3000** в конечные **0-80.**